

Guide Expert : Pipeline de Machine Learning

1. Data Cleaning (Le Nettoyage des Données)

Le nettoyage est l'étape la plus chronophage mais la plus cruciale. Elle garantit que le modèle apprend à partir de signaux et non de bruit.

- **Gestion des valeurs manquantes** : Analyser si les données manquent aléatoirement ou non. On utilise l'imputation (moyenne, médiane, ou algorithmes comme KNN) ou la suppression si les données sont trop rares.
- **Détection des outliers** : Utiliser des méthodes comme le Z-score ou l'Interquartile Range (IQR). Il faut décider de les corriger, les supprimer ou les traiter avec des méthodes robustes.
- **Traitement des doublons** : Supprimer les répétitions qui peuvent biaiser le modèle en favorisant certains points de données.
- **Normalisation et Standardisation** : Indispensable pour des algorithmes sensibles aux distances (ex: SVM, K-Means). La normalisation (Min-Max) ramène les données entre 0 et 1, tandis que la standardisation (Z-score) centre sur la moyenne avec un écart-type de 1.

2. Équilibre des classes (Class Imbalance)

Le déséquilibre survient lorsqu'une classe est largement sous-représentée. Un modèle classique risque de prédire uniquement la classe majoritaire pour minimiser son erreur.

Techniques de traitement :

- **Oversampling (SMOTE)** : Créer des échantillons synthétiques pour la classe minoritaire en interpolant entre les points existants.
- **Undersampling** : Supprimer des échantillons de la classe majoritaire. À utiliser avec précaution pour ne pas perdre d'information cruciale.

- **Class Weights** : Modifier la fonction de coût du modèle pour infliger une pénalité plus sévère lorsqu'il se trompe sur la classe minoritaire.
- **Stratégie de test** : Toujours utiliser la validation croisée stratifiée pour garantir que chaque pli contient une proportion représentative de chaque classe.

3. Feature Selection (Sélection des caractéristiques)

L'objectif est d'éliminer les variables inutiles, redondantes ou bruitées pour simplifier le modèle.

- **Méthodes de filtrage** : Basées sur des statistiques univariées (Corrélation de Pearson, Chi-deux). Elles sont rapides mais ignorent les interactions entre les variables.
- **Méthodes enveloppes (Wrappers)** : Utilisation d'un modèle pour évaluer des combinaisons de variables (ex: RFE - Recursive Feature Elimination). Très performantes mais coûteuses en temps de calcul.
- **Méthodes intégrées (Embedded)** : La sélection se fait lors de l'apprentissage (ex: Lasso L1 qui force les coefficients des variables inutiles à zéro, ou l'importance des features dans les arbres de décision).

4. Métriques de performance

Confusion Matrix : Visualise les erreurs de classification.

VP (Vrais Positifs) | FP (Faux Positifs)

FN (Faux Négatifs) | VN (Vrais Négatifs)

- **Accuracy** : $(VP + VN) / \text{Total}$. Attention, elle est trompeuse si les classes sont déséquilibrées.
- **Precision** : $VP / (VP + FP)$. Utile quand le coût d'un Faux Positif est élevé.
- **Recall (Sensibilité)** : $VP / (VP + FN)$. Utile quand le coût d'un Faux Négatif est élevé (ex: diagnostic médical).

- **ROC / AUC** : La courbe ROC montre le taux de Vrais Positifs vs Faux Positifs à divers seuils. L'AUC (Aire Sous la Courbe) mesure la capacité de séparation du modèle. Une AUC de 0.5 est aléatoire, une AUC de 1.0 est parfaite.