

# Algorithme KNN

K-Nearest Neighbors : Théorie, Mathématiques et Utilité

---



# I. Aspect Théorique


Comprendre la logique intuitive de la proximité



# Qu'est-ce que le KNN ?

Le KNN est un algorithme d'apprentissage supervisé dit "paresseux" (Lazy Learning).

- **Principe** : "Dis-moi qui sont tes voisins, je te dirai qui tu es".
- **Pas d'entraînement** : Il mémorise simplement les données.
- **Universalité** : Utilisé en classification et en régression.





# Mécanisme de Prédiction



## Classification

La prédiction est basée sur le **vote majoritaire** des K voisins. La classe la plus fréquente l'emporte.



## Régression

La prédiction est la **moyenne** (ou médiane) des valeurs des K voisins proches.



## II. Aspect Mathématique

Quantifier la similarité par la distance



# Calcul de la Proximité


Pour trouver les voisins, on calcule la distance entre un point  $P$  et un point  $Q$  dans un espace à  $n$  dimensions.

$$d(P, Q) = \sqrt{\sum_{i=1}^n (q_i - p_i)^2}$$

Distance Euclidienne (norme L2)

(DISTANCE)

Manhattan vs Euclidean



$$d_E = \sqrt{3^2 + 3^2} \approx 4.2$$

$$d_M = 3 + 3 = 6$$



# Variantes de Distance

Le choix de la métrique mathématique change la forme du voisinage :

**Manhattan (L1)**

$$\sum_{i=1}^n |q_i - p_i|$$

**Minkowski**

$$\left( \sum |q_i - p_i|^p \right)^{\frac{1}{p}}$$



# III. Utilité des Mathématiques

Pourquoi la rigueur mathématique est-elle capitale ?



# | Le Rôle de l'Échelle

Sans mathématiques, les unités faussent la distance.

Si  $X$  est en  $km$  et  $Y$  en  $mm$ ,  $Y$  dominera le calcul. Les maths imposent le **Feature Scaling** :

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

# 100%


Importance de la normalisation



# Mathématiques & Complexité

Le paramètre **K** définit la "souplesse" mathématique du modèle.

- **K faible (ex: 1)** : Frontière complexe (Surapprentissage).
- **K élevé** : Frontière lisse (Sous-apprentissage).





# Synthèse Stratégique

| Avantages                           | Limites                         |
|-------------------------------------|---------------------------------|
| Simple à implémenter                | Lent sur grands datasets        |
| Pas d'hypothèse sur les données     | Sensible aux données aberrantes |
| Efficace pour données non-linéaires | Coût mémoire élevé              |



# Questions ?

Fin de la présentation sur le KNN




# Image Sources



[https://media.geeksforgeeks.org/wp-content/uploads/20250512162457630554/Finding\\_Neighbor\\_Voting\\_for\\_Labels.webp](https://media.geeksforgeeks.org/wp-content/uploads/20250512162457630554/Finding_Neighbor_Voting_for_Labels.webp)

Source: [www.geeksforgeeks.org](https://www.geeksforgeeks.org)


---



<https://preview.redd.it/why-doesnt-the-manhattan-distance-approximate-the-euclidean-v0-d8hj6aye2fge1.png?width=1674&format=png&auto=webp&s=d70f7fb466b43d7d954f5336c178163155d81aea>

Source: [www.reddit.com](https://www.reddit.com)

---



<https://media.geeksforgeeks.org/wp-content/uploads/20240910125132/casestudy1.webp>

Source: [www.geeksforgeeks.org](https://www.geeksforgeeks.org)