

Arbres de Décision

Théorie, Mathématiques et Stratégie de Division

MASTER CLASS MACHINE LEARNING

SECTION I

Aspect Théorique


ANATOMIE D'UN ARBRE

Un arbre de décision est un modèle qui simule le raisonnement humain sous forme d'organigramme.

- **Nœud Racine** : Représente toute la population.
- **Nœuds de Décision** : Points de test sur une variable spécifique.
- **Branches** : Chemin basé sur le résultat du test (Vrai/Faux).
- **Feuilles** : Résultat final (Classe ou Valeur).

Decision Tree

A decision tree is a flowchart-like model used for classification and regression. It splits data based on features to make predictions. It looks like:



PROCESSUS DE CONSTRUCTION



Division

On fragmente les données de façon récursive pour créer des groupes homogènes.



Choix Glouton

À chaque étape, l'algorithme choisit la *meilleure* séparation immédiate.



Critère d'arrêt

L'arbre s'arrête quand les feuilles sont "pures" ou qu'une limite est atteinte.

SECTION II

Aspect Mathématique



MESURER LE DÉSORDRE

L'**Entropie** quantifie l'impureté ou l'incertitude dans un ensemble de données.

$$H(S) = - \sum_{i=1}^c p_i \log_2 (p_i)$$

Si un nœud est pur (100% même classe), l'entropie est de **0**.

Entropy vs Gini Impurity



LE GAIN D'INFORMATION

C'est la mesure mathématique de la **réduction** de l'entropie après une division.

$$\text{Gain} (S , A) = H (S) - \sum \frac{|S_v|}{|S|} H (S_v)$$

L'algorithme choisit l'attribut qui **maximise** ce gain mathématique.

ALTERNATIVE : INDICE DE GINI

Souvent utilisé par l'algorithme CART, il mesure la probabilité de mal classer un élément.

$$\text{Gini} (S) = 1 - \sum_{i=1}^c p_i^2$$

Plus rapide à calculer que l'entropie car il n'utilise pas de logarithmes.

SECTION III

Utilité des Maths

OPTIMISATION DES SPLITS

Les mathématiques permettent de transformer un problème complexe de décision en un problème d'**optimisation numérique**.

- Garantie de trouver la variable la plus discriminante.
- Permet de gérer des variables numériques en trouvant le *seuil* optimal de coupure.



MATHS CONTRE L'OVERFITTING

Un arbre trop profond apprend "par cœur". On utilise l'**Élagage (Pruning)** basé sur une fonction de coût mathématique :

$$\text{Coût} = \text{Erreur} + \alpha \times \text{Complexité (Nombre de feuilles)}$$

Les mathématiques servent à trouver le compromis idéal entre précision et simplicité (Rasoir d'Occam).

Merci !


Avez-vous des questions sur les arbres de décision ?

IMAGE SOURCES



https://media.geeksforgeeks.org/wp-content/uploads/20251216110915386263/decision_tree.webp

Source: www.geeksforgeeks.org



https://media.geeksforgeeks.org/wp-content/uploads/20251031102654718442/entropy_vs_gini_impurity.webp

Source: www.geeksforgeeks.org



https://machinelearning-basics.com/wp-content/uploads/2023/01/information_gain_featured.png

Source: machinelearning-basics.com